

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería



Proyecto 1

Métricas custom para reducción de falsos positivos en
clasificación binaria - fraude

Diego Andrés Morales Aquino

21762

Security Data Science

Guatemala, 02 de junio de 2025

Resumen

Este proyecto tiene como finalidad mejorar la detección de fraudes en un conjunto de datos transaccionales mediante el diseño y evaluación de funciones de evaluación personalizadas. El enfoque principal se centró en reducir la cantidad de falsos positivos por cada fraude identificado, mejorando así la eficiencia del sistema sin comprometer su capacidad de detección.

Como objetivo específico, se propuso optimizar la detección de fraudes en la categoría “viajes”, con un enfoque particular en transacciones relacionadas con aerolíneas, agencias de viaje y servicios similares. Para ello, se desarrollaron e implementaron múltiples métricas personalizadas en la función de evaluación (feval) de LightGBM, analizando su impacto en la precisión, cobertura y relevancia de las alertas generadas.

Durante el proceso se llevaron a cabo tareas de exploración y limpieza de datos, ingeniería de características, optimización de hiperparámetros y análisis comparativo entre las métricas propuestas. La métrica final seleccionada, `fp_ratio_weighted`, logró el mejor equilibrio entre reducción de falsos positivos y rendimiento general del modelo, con una tasa de falsos positivos de 1.08.

Metodología

1. Dataset utilizado

Se utilizó un conjunto de datos de transacciones con tarjeta de crédito entre 2019 y 2020, con la variable objetivo *is_fraud*. Las variables más relevantes incluyen el monto, tipo de comercio, hora, distancia al comercio y frecuencia de compras previas.

2. Exploración de Datos (EDA)

Se realizó un análisis visual y estadístico con herramientas como pandas, Matplotlib, Seaborn y ydata_profiling. Se identificó que la categoría “travel” tiene bajo volumen y baja tasa de fraude (0.25%), mientras que shopping_net presenta la mayor (1.6%). Las categorías con más transacciones fueron gas_transport, grocery_pos y home. Se observó una distribución bimodal en los horarios, con más actividad por la tarde y noche. Además, los fraudes tienden a tener montos más altos, y no se encontró una relación clara entre historial del cliente y probabilidad de fraude.

3. Identificación de transacciones de viajes

Durante el análisis exploratorio se identificó la categoría "travel", la cual agrupa las transacciones asociadas a servicios relacionados con viajes, como aerolíneas, agencias de viaje y transporte.

4. Ingeniería de características

Se generaron nuevas variables con el objetivo de enriquecer el dataset y capturar patrones más complejos.

5. Definición del modelo base

Se entrenó un modelo base con LightGBM usando las variables más relevantes y métricas estándar (AUC-ROC, F1, precisión y recall), sin personalizaciones ni ajuste de hiperparámetros. Su propósito fue establecer una línea base para evaluar mejoras posteriores.

6. Diseño de funciones de evaluación personalizadas

Se diseñaron varias funciones de evaluación (feval) para LightGBM con el objetivo principal de reducir la cantidad de falsos positivos sin comprometer significativamente la detección de fraudes. Las 4 funciones implementadas siguieron distintas estrategias: penalización ponderada de falsos positivos y falsos negativos según si la transacción es de viaje o no, cálculo de la razón entre verdaderos y falsos positivos ponderados, y evaluación del F0.5-score y recall, ambos también ajustados con pesos para priorizar los casos de viaje.

7. Evaluación de resultados

La evaluación final se realizó utilizando el conjunto de datos correspondiente al último mes del período de información disponible. Se comparó el rendimiento de cada función de evaluación en términos de AUC, recall, precisión, y especialmente la razón $(TP + FP) / TP$.

Implementación práctica

Ingeniería de características

Se añadieron 14 nuevas características al conjunto de datos, incluyendo:

- `amt_avg_per_visit_to_merchant`: monto promedio gastado en un comercio en específico.
- `amt_ratio_to_month_total`: representa qué porcentaje del gasto mensual corresponde a la transacción actual.
- `consecutive_transactions_same_merchant`: evalúa si son transacciones consecutivas en un mismo comercio dentro de un periodo de una hora.
- `relative_distance_vs_previous`: corresponde a la diferencia de distancia con respecto a la ubicación anterior.
- `merchant_entropy_user_level`: evalúa la diversidad de comercios en los que un usuario ha comprado, usando entropía.
- `has_traveled_far_in_a_day`: indica si en ese día el usuario ha comprado desde un lugar a más de 100km de su ubicación habitual.
- `daily_distance_traveled`: mide la distancia acumulada de las transacciones del cliente en un día.
- `Is_travel`: valor booleano que indica si la transacción actual pertenece a la categoría “travel”.
- `Year, month, day, hour, minute y second`: descomposición granular de la marca temporal en sus componentes individuales.

Optimización de hiperparámetros del modelo base

Se ajustó un modelo LightGBM con `binary_logloss` como métrica base para establecer un punto de comparación inicial. Posteriormente, se utilizó `ParameterSampler` para explorar 30 combinaciones aleatorias de hiperparámetros, evaluando el rendimiento de cada modelo entrenado. Los parámetros ajustados incluyeron `learning_rate` (0.01 a 0.1), `max_depth` (6 a 12), `num_leaves` (15, 31, 50) y `min_child_samples` (10, 20, 30). El `learning_rate` de 0.04 resultó ser el valor más determinante para mejorar el desempeño del modelo.

Funciones de evaluación personalizadas

1. `fp_penalty_weighted`

Penaliza los falsos positivos asignando mayor peso a los errores en transacciones de viajes (peso 3 frente a 1), con el fin de reducir la cantidad total de falsos positivos, especialmente en ese sector.

2. `fn_penalty_weighted`

Aplica una penalización más severa a los falsos negativos de viajes (peso 3) que a los de otras categorías (peso 1), buscando maximizar la detección de fraudes reales, especialmente en contextos críticos.

3. `fp_ratio_weighted`

Calcula la proporción entre $(TP + FP)$ y TP , ponderando cada caso según si pertenece a viajes o no, para equilibrar detección y precisión reduciendo falsos positivos sin sacrificar recall.

4. `f0.5_weighted`

Calcula el F0.5 score, una métrica que da más importancia a la precisión que al recall, y aplica mayor peso a las transacciones de viajes. Busca reducir falsos positivos sin perder demasiada capacidad de detección, priorizando alertas más confiables.

Resultados obtenidos

Métrica personalizada	fp_ratio	auc	f1_score	precision	recall
baseline	1.127536	0.994534	0.805134	0.886889	0.737179
fp_penalty	1.085937	0.857077	0.686327	0.920863	0.547009
fn_penalty	1.127536	0.994534	0.805134	0.886889	0.737179
fp_ratio (weighted)	1.084967	0.973774	0.765000	0.921687	0.653846

Métrica personalizada	fp_ratio	auc	f1_score	precision	recall
f0.5	1.127536	0.994534	0.805134	0.886889	0.737179

Matriz de confusión:

Métrica personalizada	TP	FP	TN	FN
baseline	690	88	280497	246
fp_penalty	512	44	280541	424
fn_penalty	690	88	280497	246
fp_ratio	612	52	280533	324
f0.5	690	88	280497	246

La métrica personalizada fp_ratio_weighted fue la más efectiva para reducir falsos positivos por cada fraude detectado, logrando un buen equilibrio entre precisión y recall. Al ponderar tanto los TP como los FP, con mayor peso en la categoría "travel", penaliza con más fuerza los errores críticos sin comprometer significativamente la capacidad de detección. Obtuvo un AUC alto (0.974) y redujo notablemente los falsos positivos frente a la línea base, consolidándose como la opción más adecuada para optimizar la relación TP/FP y cumplir con el objetivo del trabajo.

Si bien esta mejora en la precisión implicó una ligera reducción en la sensibilidad del modelo, con un aumento de falsos negativos de 246 a 324, la pérdida de recall fue moderada en comparación con otras métricas evaluadas. Esta decisión fue considerada aceptable, dado que el enfoque del trabajo prioriza minimizar los falsos positivos.

Conclusiones

- La métrica fp_ratio_weighted fue la que mejor cumplió el objetivo del trabajo, logrando una reducción en la cantidad de falsos positivos por cada fraude detectado, con una disminución moderada del recall.
- El simple ajuste de umbrales no fue suficiente para reducir los falsos positivos, lo que hizo necesario diseñar métricas que incorporen información contextual, como el tipo de transacción.
- El modelo base con alta AUC no garantiza un buen desempeño práctico, ya que ignoraba el costo diferencial de los errores, lo cual fue corregido al introducir funciones de evaluación alineadas con el problema real.